Systemarchitektur

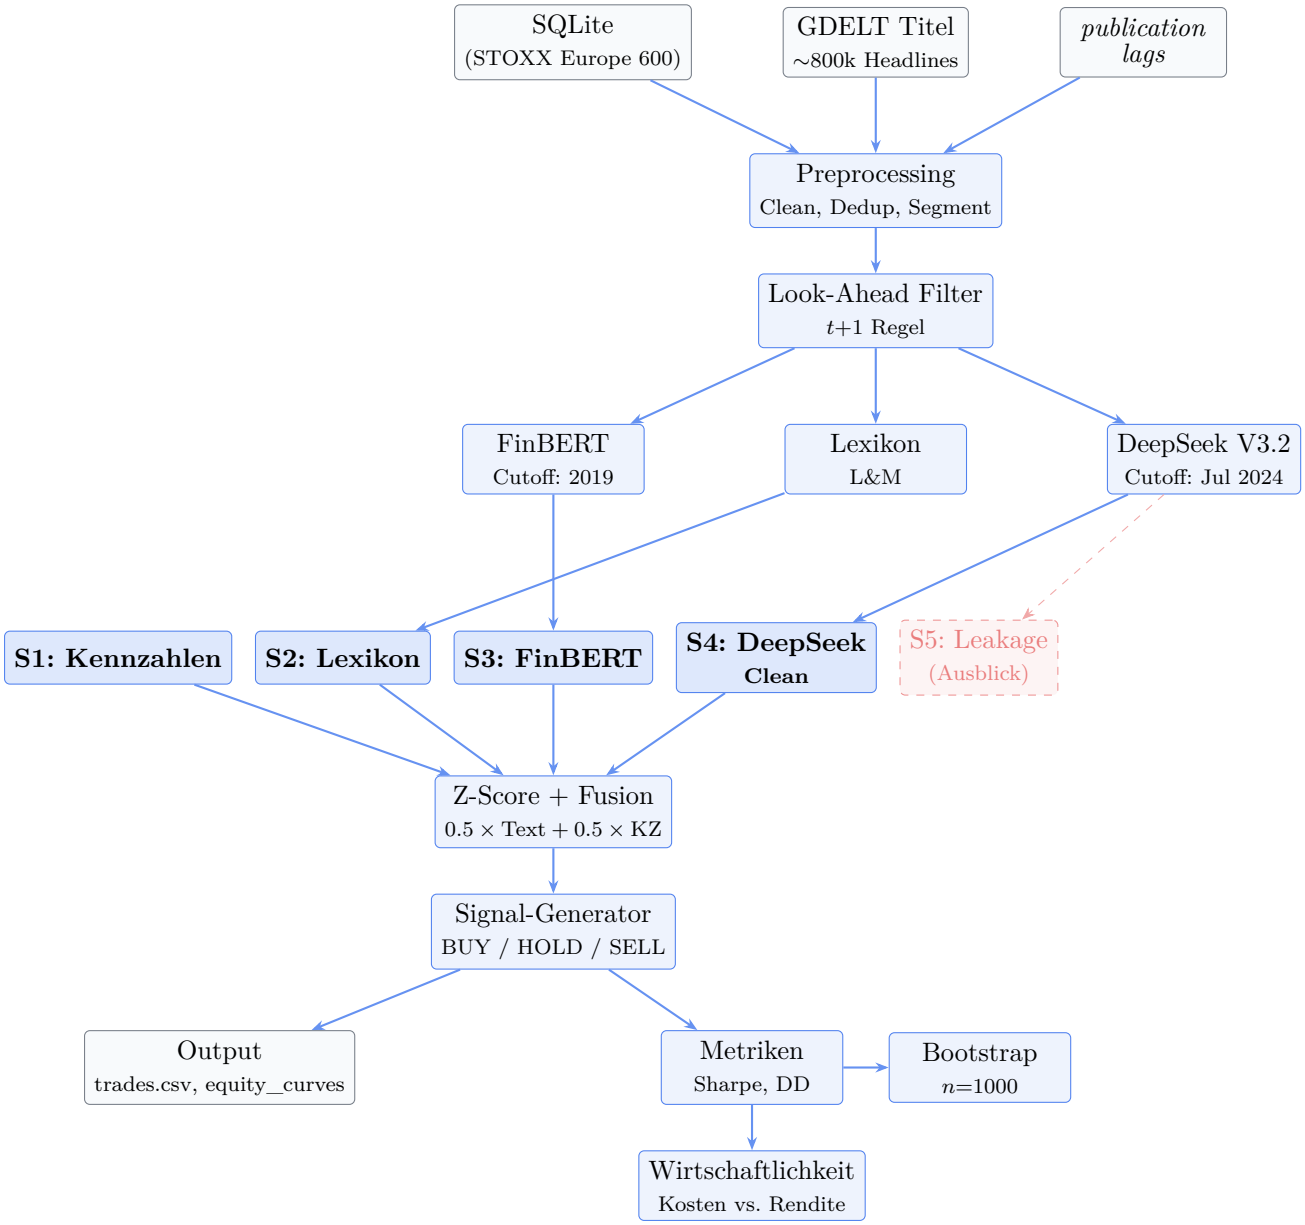
Bachelorarbeit

KI-gestützte Signale in der Aktienauswahl: Entwicklung und Evaluation eines hybriden Ansatzes mit modularer NLP-Architekturen am STOXX Europe 600

Theodor Ferdinand Frank

DHBW Sachsen – Februar 2026

1 Architektur-Übersicht



Kernidee

Vergleich von 4 Strategien (S1–S4) zur Evaluation hybrider NLP-Signale am STOXX Europe 600. S5 (Leakage-Quantifizierung) wird als Ausblick dokumentiert, fällt aber aus dem Umfang dieser Arbeit.

2 Modul-Beschreibungen

2.1 Daten-Layer

Komponente	Funktion
SQLite	Kursdaten STOXX Europe 600 (inkl. delisted!)
GDELT Titel	~800 k internationale Nachrichtentitel (Unternehmens- & Makro-News)
publication_lags	Zeitstempel: Publikation → Verarbeitung

Datenquelle & Zeitraum

GDELT Project: ∼800 000 Nachrichtentitel, Zeitraum 01.07.2024 – 31.12.2025.
Headline-Only-Ansatz: Literatur zeigt, dass bei ausreichender Nachrichtenvielfalt die Analyse reiner Titel vergleichbare Signalqualität liefert wie Volltextanalysen (geringerer Tokenverbrauch, höherer Durchsatz).

Kritisch

Survivorship Bias vermeiden durch Einschluss delisteter Unternehmen.

2.2 Preprocessing Layer

- **Text Cleaning:** HTML-Tags, Sonderzeichen, Encoding-Artefakte entfernen
- **Deduplizierung:** Fingerprinting auf Titel-Ebene (gleiche Meldung, mehrere Quellen)
- **Entity Matching:** GDELT-Titel → STOXX-600-Unternehmen (Ticker / Name Mapping)

2.3 Look-Ahead-Bias Filter

Zeitstempel-Regel:

Meldung am 15.03.2024 um 14:30 Uhr
→ Signal gilt für 16.03.2024
→ Kurs: Opening Price oder VWAP

Häufigster Fehler in akademischen Arbeiten

Same-Day Trading mit Informationen, die erst nach Börsenschluss verfügbar waren.

2.4 Modell-Layer

Modell	Typ	Cutoff	Charakteristik
FinBERT	Lokal	∼2019	Zeit-invariant (Kontrolle)
Lexikon	Statisch	–	Loughran-McDonald
DeepSeek V3.2	API	Jul 2024*	Post-Cutoff für Datenfenster

*Empirisch ermittelt via strukturiertem Cutoff-Test (15 Wissensfragen mit absteigendem Aktualitätsgrad, ohne Internetzugang). DeepSeek V3.2 beantwortet Olympia Paris 2024 korrekt, alle Ereignisse ab August 2024 mit „keine verlässlichen Trainingsdaten“. → Effektiver Cutoff: ∼Juli 2024.

Versionierung speichern:

- `model_version`: `"deepseek-v3.2"`
- `api_timestamp`
- `temperature`, `seed`

2.5 Die 4 Strategien

Nr.	Strategie	Status
S1	Kennzahlen only	✓ Baseline
S2	Lexikon + Kennzahlen	✓ Benchmark
S3	FinBERT + Kennzahlen	✓ Main (zeit-invariant)
S4	DeepSeek V3.2 + Kennzahlen (post-cutoff)	✓ LLM-Strategie

Strategie S5 – Ausblick

S5: Leakage-Strategie (DeepSeek auf Pre-Cutoff-Daten $\leq$ Jul 2024) wird in dieser Arbeit nicht implementiert, da sie den Rahmen sprengen würde. Sie wird jedoch als methodischer Ausblick beschrieben: Durch gezielten Einsatz des LLM auf Daten *innerhalb* seines Trainingszeitraums ließe sich der Data-Leakage-Bias via Δ-Analyse quantifizieren (vgl. Abschnitt 5).

2.6 Normalisierung & Fusion

Z-Score Transformation (cross-sectional):

$$z_{i,t} = \frac{x_{i,t} - \bar{x}_t}{\sigma_t}$$

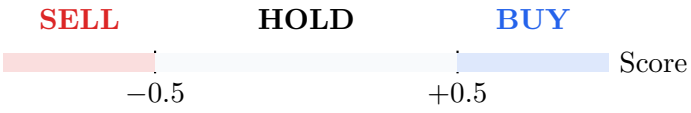
wobei $\bar{x}_t$ der Durchschnitt über alle Aktien am Tag t.

Fusion:

$$\text{Score}_{\text{final}} = 0{,}5 \times \text{Text-Signal} + 0{,}5 \times \text{Kennzahlen-Signal}$$

Alternative: ML-optimierte Gewichte (In-Sample Jul–Dez 2024)

2.7 Signal-Generator



Die neutrale Zone $[-0{,}5,\ +0{,}5]$ verhindert übermäßiges Trading bei unsicheren Signalen.

3 Analyse-Framework

3.1 Metriken

- **Sharpe Ratio:** $\frac{\bar{r} - r_f}{\sigma_r}$ (Out-of-Sample!)
- **Max Drawdown:** Maximaler Verlust vom Peak
- **CAGR:** Compound Annual Growth Rate
- **Win Rate:** Anteil profitabler Trades
- **Turnover:** Handelsaktivität

3.2 Block-Bootstrap Test

Warum Block-Bootstrap?

Finanzielle Zeitreihen sind nicht i.i.d. – Autokorrelation muss erhalten bleiben.

Parameter:

- $n = 1000$ Wiederholungen
- H_0: Sharpe Ratio $= 0$
- Block-Länge: $\sim$20 Handelstage

3.3 Wirtschaftlichkeitsanalyse

Die Strategien werden nicht nur nach risikoadjustierter Performance bewertet, sondern auch hinsichtlich ihrer ökonomischen Tragfähigkeit unter realistischen Annahmen.

Kostenkomponenten:

- **API-Kosten:** DeepSeek V3.2 Token-Verbrauch pro Rebalancing-Zyklus (∼800k Titel × Tokens/Titel)
- **Datenkosten:** GDELT (kostenlos), Kursdaten-Feed
- **Infrastruktur:** Rechenzeit FinBERT (lokal), API-Latenz
- **Transaktionskosten:** je nach Modell (pauschal / spread-basiert)

Rendite-Kosten-Verhältnis:

$$\text{Netto-}\alpha = \text{Brutto-}\alpha_{\text{Strategie}} - \underbrace{C_{\text{API}} + C_{\text{TK}} + C_{\text{Infra}}}_{\text{Gesamtkosten p. a.}}$$

Ziel: Für jede Strategie S1–S4 das Break-Even-Kapital bestimmen, ab dem die Signalkosten durch die Mehrrendite gegenüber dem Benchmark gedeckt werden.

Skalierungseffekt

API-Kosten sind weitgehend fix pro Rebalancing (unabhängig vom Portfoliovolumen), während die Brutto-Rendite proportional zum Kapital skaliert. → Je größer das Portfolio, desto günstiger die Kosten-Rendite-Relation.

4 Technische Umsetzung

4.1 Docker-Container Setup

```
thesis-backtest/
  docker-compose.yml
  data/
    sqlite/
      stoxx600.db
    gdelt/
      titles_800k.csv
  models/
    finbert/
  src/
    preprocessing/
    strategies/
    backtest/
    analysis/
  output/
    trades.csv
    equity_curves.csv
    charts/
```

4.2 Hardware-Hinweise

Komponente	Empfehlung
Datenbank	SQLite (nicht Postgres – spart RAM)
FinBERT	∼440 MB, nicht parallel zur DB
DeepSeek V3.2	Externe API (kein lokales Hosting)
RAM	Mindestens 8 GB empfohlen

5 Ausblick

5.1 S5: Data-Leakage-Quantifizierung (Future Work)

Die folgende Erweiterung wurde bewusst aus dem Umfang der Bachelorarbeit ausgeklammert, bietet jedoch einen direkten Anschluss zur weiteren Validierung des Modells.

Idee: DeepSeek V3.2 wird zusätzlich auf Nachrichtentitel aus dem Zeitraum *vor* seinem Knowledge Cutoff (d. h. $\leq$ Juli 2024) angewendet – einem Zeitraum, über den das Modell potenziell Trainingswissen besitzt. Durch Vergleich mit dem zeit-invarianten FinBERT lässt sich der Leakage-Bias isolieren:

$$\text{Spread}_{\text{pre}} = \text{Sharpe}_{\text{DeepSeek}} - \text{Sharpe}_{\text{FinBERT}} \quad \text{(Pre-Cutoff)} \tag{1}$$

$$\text{Spread}_{\text{post}} = \text{Sharpe}_{\text{DeepSeek}} - \text{Sharpe}_{\text{FinBERT}} \quad \text{(Post-Cutoff)} \tag{2}$$

$$\Delta_{\text{Leakage}} = \text{Spread}_{\text{pre}} - \text{Spread}_{\text{post}} \tag{3}$$

Ein $\Delta > 0$ würde darauf hindeuten, dass DeepSeek im Pre-Cutoff-Zeitraum einen unfairen Informationsvorteil besitzt. Voraussetzung wäre eine Erweiterung des Datenzeitraums um mindestens 6–12 Monate vor Juli 2024, um ausreichende statistische Power zu gewährleisten.

6 Offene Fragen

✓ **Index-Wahl:** STOXX Europe 600 – *entschieden*
✓ **Nachrichtenquelle:** GDELT Project, ∼800k Titel – *entschieden*
✓ **LLM-Wahl:** DeepSeek V3.2, Cutoff empirisch bei Jul 2024 – *entschieden*

1. **DeepSeek-Modelldetails (offen):**
   - Exakter Trainings-Datenumfang und -quellen?
   - Verhalten bei europäischen vs. US-zentrischen Headlines?
   - Optimale Prompt-Struktur für Titel-Sentiment?
   - Reproduzierbarkeit: Seed-Stabilität über API-Versionen?
2. **Startkapital & Skalierung:**
   - Welches Startkapital wird simuliert? (z. B. 100 k€ vs. 10 Mio.€)
   - Einfluss auf Positionsgrößen, Liquiditäts-Constraints, Slippage
   - Break-Even-Kapital: Ab welchem Volumen deckt die Mehrrendite die API-Kosten?
3. **Survivorship Bias:**
   - Quelle für delisted Companies im Zeitraum Jul 2024 – Dez 2025?
   - Oder: Bias dokumentieren und akzeptieren (kurzer Zeitraum)
4. **Transaktionskosten:**
   - Pauschal (z. B. 10 bps)?
   - Spread-basiert?

Dieses Dokument dient als Konzept-Übersicht für die Bachelorarbeit-Diskussion.